周风余

教授，博士生导师，国家重点研发计划“服务机器人云服务平台”项目首席科学家，获得国家科学技术进步奖二等奖 1 项．研究领域为模式识别与机器智能、机器人云服务平台、服务机器人故障自诊断、机器人类人导航．主持国家自然科学基金项目“基于云的服务机器人在线故障自诊断方法研究”．该项目提出了与人类自我健康评估及就医诊断过程相似的研究思路，基于云服务平台对服务机器人故障样本的获取、故障高层次特征的自适应学习和云一端结合的在线故障自诊断方法进行了综合研究，建立了一套云基服务机器人在线故障自诊断方法理论体系，为服务机器人的安全保障提供了理论技术支撑．

DOI：10.13973/j.cnki.robot.200295

基于 SE-CNN 的服务机器人运动系统云端故障诊断方法

缪昭明[1]，袁宪锋[2]，张　晖[3]，颜　亮[3]，周风余[1]，郭仁和[1]，汪佳宇[1]

（1. 山东大学控制科学与工程学院，山东 济南　250061；　2. 山东大学机电与信息工程学院，山东 威海　264209；
3. 浪潮集团有限公司，山东 济南　250011）

摘　要：研究并设计了一种基于服务机器人云平台的故障诊断系统．传统算法只关注服务机器人某一时刻的状态数据，所提取的特征信息有限，因而难以较好地完成故障诊断任务．在这种背景下，提出了基于时间序列关联特征的故障诊断方法．首先，对采集的服务机器人数据进行归一化和后向差分预处理，消除数据量纲并获取数据变化特征；其次，利用滑动窗口来生成时间序列样本，保证每个样本包含足够的特征信息；然后，应用卷积神经网络（CNN）挖掘时间序列的关联特征，并在网络中引入通道注意力网络（squeeze-and-excitation network，SENet），构建了一种 SE-CNN 模型．该模型能够自适应调整特征通道的重要程度，聚焦于更有效的特征通道，从而提高了诊断精度．对比实验与实际场景下的综合测试证明了本文提出的故障自诊断方法的可行性和有效性．

关键词：服务机器人；故障诊断；云服务；关联特征

中图分类号：TP242.6　　**文献标识码**：A　　**文章编号**：1002-0446(2021)-03-0321-10

Cloud Fault Diagnosis Method of a Service Robot Motion System Based on SE-CNN

MIAO Zhaoming[1]，YUAN Xianfeng[2]，ZHANG Hui[3]，YAN Liang[3]，ZHOU Fengyu[1]，GUO Renhe[1]，WANG Jiayu[1]

(1. *School of Control Science and Engineering, Shandong University, Jinan* 250061, *China*;
2. *School of Mechanical, Electrical & Information Engineering, Shandong University, Weihai* 264209, *China*;
3. *Inspur Group Co. LTD, Jinan* 250011, *China*)

Abstract: A fault diagnosis system based on a service robot cloud platform is studied and designed. Since the traditional algorithms only focus on the state data of the service robot at a particular time, the extracted feature information is limited. Therefore, it is difficult for the traditional algorithms to complete the fault diagnosis task well. In this context, a fault diagnosis method based on the correlation features of the time series is proposed. Firstly, the collected service robot data are pre-processed by normalization and backward difference to eliminate the data dimension and obtain the data change characteristics. Secondly, the sliding window is employed to generate time series samples to ensure that each sample contains sufficient feature information. Then, convolutional neural network (CNN) is applied to extracting correlation features of time series, and channel attention networks (squeeze-and-excitation network, SENet) are introduced to construct an SE-CNN model, which can adaptively adjust the importance of feature channels and focus on more effective feature channels, thereby improving diagnosis accuracy. Comparative experiments and comprehensive test in the actual scene prove the feasibility and effectiveness of the fault self-diagnosis method proposed.

Keywords: service robot; fault diagnosis; cloud service; correlation feature

基金项目：国家重点研发计划（2017YFB1302400）；国家自然科学基金（61773242，61803227）；山东省农业重大应用技术创新项目（SD2019NJ014）；山东省自然科学基金（ZR2019MF064）．
通信作者：周风余，zhoufengyu@sdu.edu.cn
收稿/录用/修回：2020-08-07/2020-10-06/2020-10-08

1 引言（Introduction）

在人口老龄化和劳动力成本居高不下的背景下，服务机器人必将走上历史舞台，成为人类不可或缺的最密切的朋友和家庭生活的一员，彻底改变这个时代的生活方式．目前服务机器人难以普及的主要原因一是产品智能化及服务水平比较低，二是产品安全性没有保障．2017 年，王天然院士[1]提出“与人共融”是下一代服务机器人的发展方向，服务机器人的安全性和可靠性必须引起足够重视[2]．因此，对服务机器人故障自诊断方法进行研究是当前非常急迫的任务，意义重大．

传统的工业机械臂因其运动学和动力学数学模型完备，且工作环境和运行状态相对固定，因此，针对机械臂的故障诊断研究大多采用基于模型的诊断方法．服务机器人自身装备有多种异构传感器，在运行过程中会积累大量的异源数据，此外，服务机器人运行环境和工作状态多变，获取其精确数学模型相对困难．基于数据驱动的智能故障诊断方法不需要精确的系统模型，从历史和当前数据出发，通过信号处理、机器学习等方法挖掘故障知识[3-5]，因此，该类方法更加适合于家庭服务机器人的故障诊断问题，逐渐成为研究热点[6-8]．文 [9] 提出一种基于改进深度信念网络（deep belief network，DBN）的故障诊断方法，采用不精确线性搜索算法与遗传算法对 DBN 权重值以及受限玻尔兹曼机的隐层神经元进行优化调整，并应用改进的 DBN 模型对机器人惯性测量单元（IMU）常见故障进行诊断．文 [10] 提出一种踏板机器人故障诊断方法，分别采用主成分分析（PCA）、t-SNE（t-distributed stochastic neighbor embedding）和 AutoEncoder 算法提取数据特征，然后融合提取的特征并使用 Treelet 变换进行特征降维，最后，通过高斯过程分类器对故障样本进行分类．Hoang 等[11]通过建立三层神经网络来估计过程故障引起的移动机器人动力学偏差，当残差超过设定阈值时认为有故障发生．文 [12] 结合多传感器信息融合及支持向量机（SVM）等方法，针对机械手经常遇到的移动受阻、前方碰撞和侧面碰撞 3 种故障模式，开展故障诊断研究．Khaldi 等[13]结合 PCA 和指数加权移动平均值等算法提出了一种数据驱动的群机器人故障诊断算法，利用机器人群体和个体之间的数据信息，对群机器人系统常见的 6 种故障问题进行了故障诊断研究，通过仿真实验证明了所提方法的有效性．文 [14] 结合粒子滤波和 SVM 方法提出了适用于轮式移动机器人运动系统的故障诊断方法，该方法能够避免传统粒子滤波中故障诊断阈值需要经验设定的问题．文 [15] 将服务机器人运动系统故障诊断问题划分为传感器故障和机械子系统故障，设计了一种用于服务机器人故障诊断的软件仿真平台，利用 PCA 和神经网络等方法实现了机器人运动系统 5 种常见故障的诊断．

上述研究成果极大地推动了基于数据驱动的故障诊断方法的发展，但仍存在一些不足之处，比如，诊断模型仅对某一时刻的故障数据提取特征，未考虑其相邻时刻故障数据间的关联特征；训练样本涵盖信息不足，导致系统故障诊断准确率无法进一步提高．此外，基于数据驱动的故障诊断算法在故障特征提取和诊断模型训练环节对计算和存储能力有较高的需求，仅依靠个体服务机器人自身能力难以满足复杂算法对算力的要求[16-17]．

针对上述问题，本文以服务机器人运动系统电机轴偏心、电机故障、编码器故障以及 IMU 故障等几类常见的故障问题为例，提出了一种基于时间序列关联特征的服务机器人运动系统云端故障诊断方法．首先，采用归一化与后向差分的方式对原始数据进行预处理；其次，采用滑动窗口处理方法生成时间序列样本，保证单个样本涵盖足够的特征信息；然后，基于 CNN 模型，挖掘数据的关联特征，并引入通道注意力网络，使模型自适应地聚焦于含有更多有效特征的通道；最后，由 Softmax 分类器得到准确的故障类型．另外，为了解决服务机器人本体计算及存储能力小的问题，设计了一种基于云平台的故障诊断架构，将特征提取、模型训练等大计算量环节卸载至云端，诊断结果以及训练好的诊断模型通过云机接口反馈至服务机器人，巧妙解决了机器人本体硬件资源与算力的矛盾．大量实验结果表明，本文方法具有较高的故障诊断准确率．

2 服务机器人运动系统故障分析及诊断框架设计（Design of the fault analysis and diagnosis framework for a service robot motion system）

2.1 故障分析

服务机器人系统中，运动控制子系统故障率高且后果最严重，因此对该部分的故障诊断具有更高的研究价值[18-19]．本文重点研究发生概率较高且危险程度较大的 5 种故障，如表 1 所示．

表 1 故障类型

Tab.1 Fault types

故障类别	正常状态	电机轴偏心	编码器故障	电机无法驱动	IMU 噪声	IMU 常值偏移
故障码	00	01	02	03	04	05

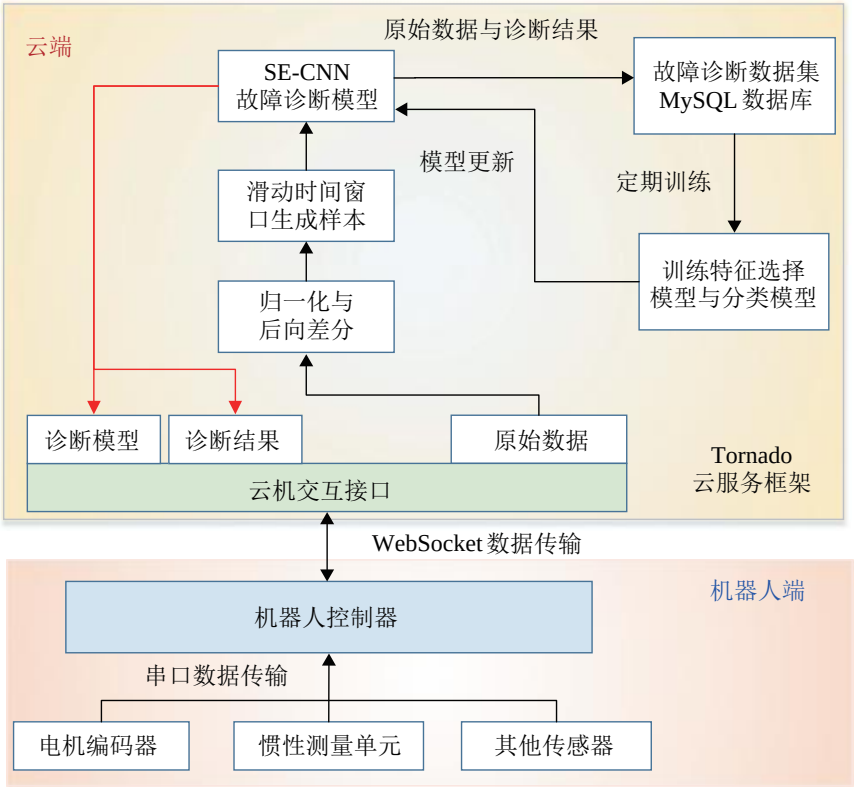

图 1　云端故障诊断架构

Fig.1　Cloud fault diagnosis architecture

2.2　故障诊断系统框架

基于云平台的服务机器人不仅具有向云端上传计算密集型任务、大数据挖掘和知识共享等能力，还可以扩展机器人的功能，使服务机器人大幅度“瘦身”，变得更加轻巧、廉价和智能[20]．2013 年，Kuffner 教授[21] 利用谷歌物体识别引擎实现了云机器人的抓取操作，受到了国内外学者的广泛关注．同年，Tenorth 等[22] 提出了一种用于机器人共享知识的机器人万维网 RoboEarth，该网络可为机器人提供动作序列、对象模型等语义信息，以便机器人更好地完成服务任务．2015 年，加州大学伯克利分校 Goldberg 等[23] 基于云计算技术并行实现了蒙特卡洛采样算法，并利用 Google 目标识别引擎完成了 PR2 机器人的抓取任务．2019 年，本文研发团队在国家重点研发计划项目资助下设计开发了一种通用的服务机器人云平台[24]，平台基于机器学习、深度学习等封装了大量的个性化智能云服务，采用 JSON 语言实现了服务机器人的高效服务调度，目前可以实现大规模异构服务机器人的高并发接入和云服务调用．本文基于该云平台，提出了一种新型的服务机器人故障诊断架构，如图 1 所示，主要包括云端和服务机器人端 2 个部分，图中箭头为数据流方向．

服务机器人端负责采集运动控制系统各传感器的数据，通过 WiFi 模块将数据上传到云端．机器人与云端采用 WebSocket 长连接方式进行实时通讯．

云端采用 Tornado Web 云服务框架，与服务机器人建立长连接后，首先，对接收到的原始数据进行归一化处理，消除数据的量纲；再对数据求取 1 阶和 2 阶后向差分，分别获得原始数据变化以及变化率特征；然后，对升维后的数据进行滑动窗口处理，生成样本；最后，将得到的样本输入 SE-CNN 模型中获得故障诊断结果．诊断结果通过云机接口反馈给服务机器人，并与原始数据一起存储入云端故障诊断数据库．

与传统故障诊断架构相比，本文所提服务机器人云端故障诊断架构的优势主要在于：

(1) 云平台的引入，巧妙解决了机器人本体计算和存储资源有限与复杂故障诊断算法对计算和存储能力要求高的矛盾，可以降低服务机器人成本，推动服务机器人的产业化进程；

(2) 通过设计合理的机器人云平台知识共享机制，云端训练好的故障诊断模型可被同类型的服务机器人快速复用和共享，达到机器人间的“一人学会，大家都会”效果．

3 时间序列特征与样本生成（Time series characteristics and sample generation）

3.1 时间序列的关联特征

传统的基于机器学习的故障诊断方法通常使用 SVM、决策树以及人工神经网络等算法[25-26]．然而，这些算法仅对某一时刻的数据进行处理分析与特征提取，均未考虑相邻时刻数据间的关联特性．由于服务机器人的运动状态非常复杂，传感器的数据分布存在多样性和时间相关性．某一个时刻的传感器数据所包含的特征信息往往是有限的，难以体现数据间的相关性与数据的变化规律，因此将上述传统方法直接用于服务机器人故障诊断具有较大的局限性，无法保证诊断精度．

时间序列的关联特征除了包括数据数值大小特征，还包括变量间的关联特征以及变量自身的变化特征．下面分别举例说明．

(1) 变量间的关联特征：如图 2 所示，当四轮服务机器人拐弯时，轮子速度间表现出一定的相关性，类似地，其他传感器数据在机器人的运行过程中也会呈现某种关联性．

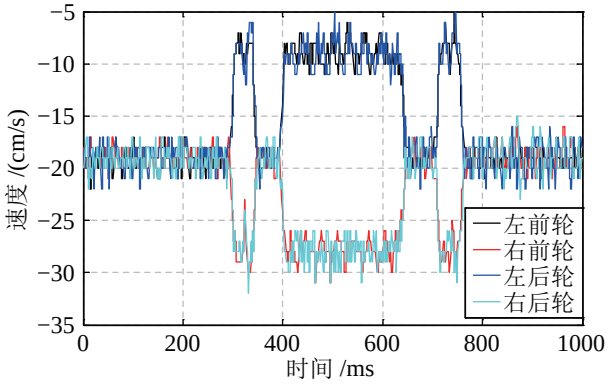

图 2 变量间的关联特征示意图

Fig.2 Diagram of correlation features between variables

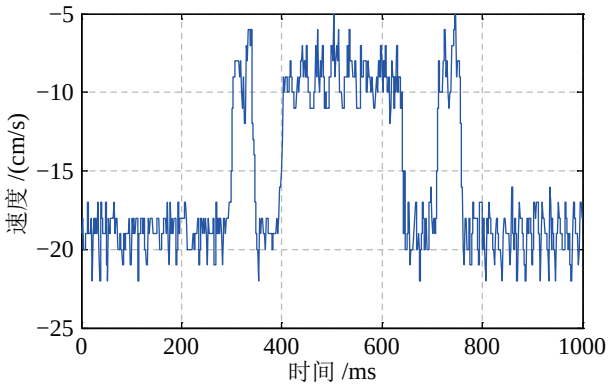

图 3 左后轮速度变化曲线

Fig.3 Speed change curve of the left rear wheel

(2) 变量自身变化特征：如图 3 所示，服务机器人在拐弯过程中左后轮速度数值变化有一定规律性．当机器人处于其他运动过程中，各传感器数值变化也会表现出一定的趋势性．

当机器人处于故障状态下，机器人的运动方式以及传感器的数据都会发生变化，进而影响变量间的关联性与变量自身变化的规律性．因此，时间序列的关联特征对机器人不同状态的数据具有更本质的刻画，更加适合用于服务机器人的故障诊断．

3.2 滑动窗口的时间序列样本生成

为提取时间序列的关联特征，需要将一段时间的数据输入到模型中，比原始服务机器人数据多 1 个维度．本文采用滑动窗口处理方法来生成样本，详细的操作步骤如下：

Step 1：采用 Pandas 数据处理工具读入传感器数据文件，转化为 DataFrame 格式，并依据时间戳合并．

Step 2：首先对数据进行最大最小值归一化处理，再对归一化后的数据求取 1 阶和 2 阶后向差分．原始数据维度为 13，经过后向差分处理后，数据维度升为 39．

Step 3：采用图 4 所示的滑动窗口方式，生成时间序列样本．滑动窗口需要设定窗口大小和移动步长．本文设置窗口大小与步长分别为 50 和 10．

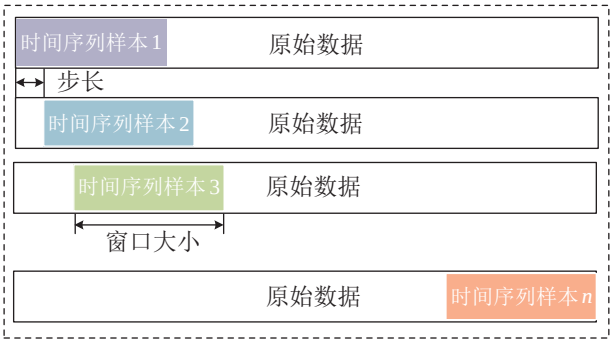

图 4 滑动窗口样本生成示意图

Fig.4 Diagram of the sliding window sample generation

经过上述 3 步处理后，生成的每个时间序列样本大小为 50×39．

4 SE-CNN 故障诊断模型（SE-CNN fault diagnosis model）

4.1 CNN 诊断原理

CNN 是一种典型的前馈神经网络，由卷积层、池化层和全连接层组成．CNN 的每级通常包含卷积层与池化层，通过多次的卷积与池化交替运算，提取输入数据的关联特征；最后利用全连接层将特征图矩阵转化为 1 维矢量，并输入到分类器中实现

故障分类.

卷积层是 CNN 的核心模块，肩负着网络的主要计算任务．卷积层通过卷积核对输入特征图进行卷积运算，并利用非线性激活函数计算输出特征图．同一个卷积核在卷积过程中权值不变，即权值共享．卷积运算可表示为

$$\boldsymbol{x}_j^r = \boldsymbol{f}\left(\sum \boldsymbol{x}_i^{r-1} \times \boldsymbol{k}_{ij}^r + \boldsymbol{b}_j^r\right) \tag{1}$$

式中，$\boldsymbol{x}_j^r$ 表示第 r 层卷积层计算所得的第 j 个输出特征图，$\boldsymbol{b}_j^r$ 表示第 r 层网络中第 j 个卷积核的偏置向量，$\boldsymbol{k}_{ij}^r$ 表示与第 i 个输入特征图相运算的第 j 个卷积核．$\boldsymbol{f}$ 代表非线性激活函数，通常选择 ReLU（rectified linear unit）函数，以提高网络的拟合能力与稀疏性.

池化层通过池化核对输入特征图进行缩放映射，在降低数据维度的同时提取特征．常用的池化函数包含平均池化和最大池化，本文采用的是最大池化函数，其计算方法为

$$\boldsymbol{y}_{ijk} = \max\left(\boldsymbol{y}_{mnk} : i \leqslant m \leqslant i+p,\ j \leqslant n \leqslant j+t\right) \tag{2}$$

式中，p 和 t 代表池化核的长和宽，经过最大池化运算，$p \times t$ 范围内最大值将保留到输出特征图中，作为该区域所对应的新特征，从而实现缩小特征图的目的，减小计算量.

全连接层对最后一个池化层的所有神经元进行全连接，其模型可描述为

$$\boldsymbol{O}(\boldsymbol{x}) = \boldsymbol{f}(\boldsymbol{w}\boldsymbol{x} + \boldsymbol{b}) \tag{3}$$

式中，$\boldsymbol{x}$ 为全连接层的输入，$\boldsymbol{w}$ 为权值矩阵，$\boldsymbol{b}$ 为偏置向量.

4.2　SENet

在使用 CNN 网络开展机器人故障诊断时，一些无效的信息也会被网络提取．无效的信息分布在特征图的某些通道上，分散了 CNN 网络的“注意力”，阻碍了故障诊断准确率的提升．针对此问题，本文引入了 SENet．该网络能够自适应学习得到每个特征通道的重要程度，并通过赋予特征图的各通道不同的权值，调整特征通道的重要性，使模型聚焦于具有更多有效特征信息的通道，提升模型的故障诊断精度．其典型结构如图 5 所示.

图中，$\boldsymbol{X} \in \mathrm{R}^{H \times W \times C}$ 代表输入特征图，H 与 W 表示特征图的长与宽，C 代表通道数．为得到输入特征图各通道的权重，SENet 将进行 2 步操作．首先，SENet 采用全局平均池化函数，对每一个特征

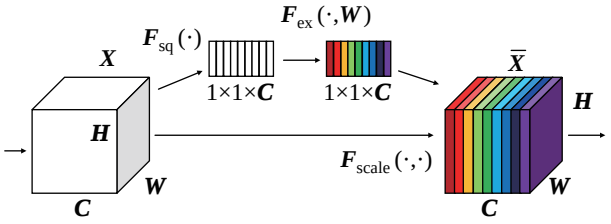

图 5　通道注意力模型

Fig.5　Channel attention model

通道在空间维度 $H \times W$ 上进行压缩（squeeze），其计算公式如下：

$$\boldsymbol{Z} = \boldsymbol{F}_{\mathrm{sq}}(\boldsymbol{X}_{\mathrm{c}}) = \frac{1}{H \times W}\sum_{i=1}^{H}\sum_{j=1}^{W}\boldsymbol{X}_{\mathrm{c}}(i,j) \tag{4}$$

式中，$\boldsymbol{Z}$ 代表压缩操作生成的权重．SENet 第 2 步执行激励操作（excitation）．激励操作的目的是获取特征通道之间的相关性．为此，SENet 采用了带有一个隐含层的感知机，其隐含层的神经元个数为 C/l，l 为缩放比例，适当的缩放比例可以减少网络的参数并增强泛化能力，这里 l 取值为 16．在感知机之后使用 Sigmoid 函数计算最终的特征通道权重．激励操作的计算过程可表示为

$$\boldsymbol{S}_{\mathrm{c}} = \boldsymbol{F}_{\mathrm{ex}}(\boldsymbol{Z},\boldsymbol{W}) = \boldsymbol{\sigma}(\boldsymbol{g}(\boldsymbol{Z},\boldsymbol{W})) = \boldsymbol{\sigma}(\boldsymbol{W}_2\delta(\boldsymbol{W}_1\boldsymbol{Z})) \tag{5}$$

式中，δ 表示 ReLU 函数，$\boldsymbol{\sigma}$ 表示 Sigmoid 函数，$\boldsymbol{S}_{\mathrm{c}}$ 表示生成的通道注意力权重，其维度为 $1\times1\times C$.

最后，将权重 $\boldsymbol{S}_{\mathrm{c}}$ 加入到原始的特征通道中，实现通道重要性的调整，计算公式为

$$\bar{\boldsymbol{X}}_C = \boldsymbol{F}_{\mathrm{scale}}(\boldsymbol{X}_{\mathrm{c}},\boldsymbol{S}_{\mathrm{c}}) = \boldsymbol{X}_{\mathrm{c}} \otimes \boldsymbol{S}_{\mathrm{c}} \tag{6}$$

式中，$\otimes$ 代表逐元素相乘，$\bar{\boldsymbol{X}}_C$ 代表经过 SENet 处理输出的特征图.

4.3　SE-CNN 故障诊断模型设计

为实现服务机器人的精确故障诊断，本文使用 CNN 提取时间序列的关联特征，并引入了 SENet，构建了一种 SE-CNN 故障诊断模型，其架构如图 6 所示.

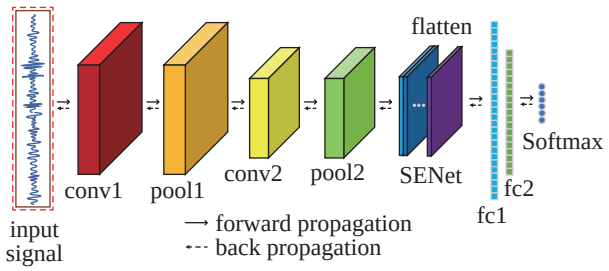

图 6　SE-CNN 故障诊断模型

Fig.6　SE-CNN fault diagnosis model

模型主要由 2 个卷积层、2 个池化层、1 层 SENet 结构、2 个全连接层以及 1 个 Softmax 分类器构成，模型的具体参数以及每层的输出特征数如表 2 所示.

表 2 SE-CNN 参数

Tab.2 Parameters of SE-CNN

网络层	网络层参数	输出特征参数
conv1	3×3×32	32×50×39
pool1	3×3	32×17×13
conv2	3×3×32	32×17×13
pool2	2×2	32×9×7
SENet	–	32×9×7
fc1	2016	192
fc2	192	6

具体工作流程为：样本数据通过 2 层卷积层与池化层提取出时间序列的关联特征；然后，由 SENet 对特征图各通道的重要性进行调整，提升有效特征通道的利用程度并抑制无效的特征通道；最后由全连接层与 Softmax 分类器得出诊断结果.

5 故障诊断实验（Fault diagnosis experiments）

5.1 实验条件与数据获取

本文选择运动系统较为复杂的 4 麦克纳姆轮型服务机器人为研究对象，如图 7 所示. 用于故障诊断的传感器主要有 4 个编码器和 1 个 9 轴 IMU（惯性测量单元），传感器的采样频率为 100 Hz. 运行过程中，机器人将传感器数据实时上传至云端进行处理，网络的传输速率为 100 Mb/s.

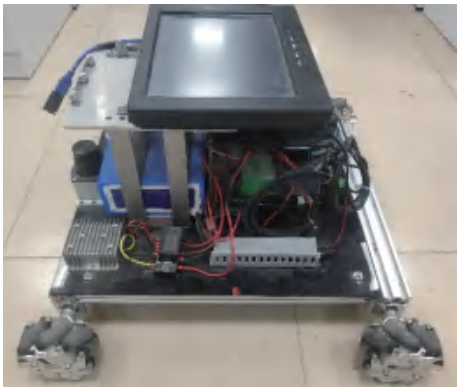

图 7 麦克纳姆轮服务机器人

Fig.7 The service robot with Mecanum wheels

图 8 展示了正常状态、编码器故障以及 IMU 噪声 3 种状态下 200 s 内的编码器数据分布情况. 由图所示，3 种状态下编码器数据存在差异，这是由于机器人发生故障会导致机器人运动方式发生改变；此外，数据采集过程中，机器人处于漫游状态，在不同状态下机器人的运动过程不尽相同.

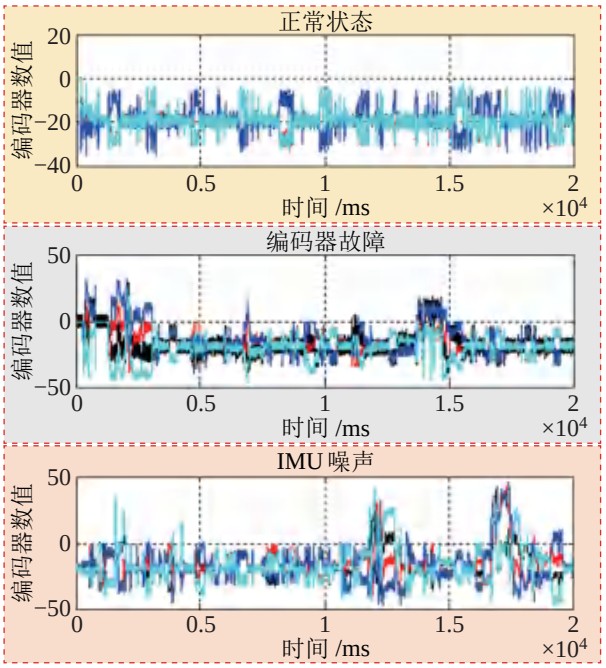

图 8 3 种状态下的部分编码器数据

Fig.8 Partial encoder data in three states

云端收集到机器人传感器数据后，按照 3.2 节的方法对数据进行处理，各类别原始数据大小与生成的样本数据大小如表 3 所示.

表 3 原始数据与样本数据

Tab.3 Raw data and sample data

故障码	原始数据	样本数据
00	65000×13	6496×50×39
01	25000×13	2496×50×39
02	25000×13	2496×50×39
03	65000×13	6496×50×39
04	30000×13	2996×50×39
05	60000×13	5996×50×39

各类别一个样本转换成 2D 灰度图，如图 9 所示. 由图可知，不同状态下的机器人传感器数据转化得到的 2D 灰度图之间有着一定的区别.

5.2 故障诊断实验

为了验证 SE-CNN 故障诊断模型的有效性，本文对 CNN 模型与 SE-CNN 模型进行对比实验. 实验中，前 70% 的样本数据作为训练集，后 30% 的数据作为测试集，2 种模型采用相同的训练集和测试集，取后 10 轮的平均测试准确率为最终的诊断结果. 值得注意的一点是，由于采用滑动窗口处理

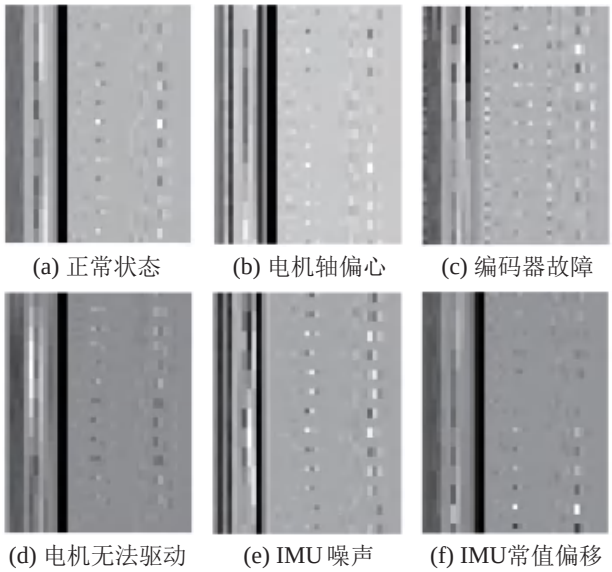

图 9　2D 灰度图

Fig.9　The two-dimensional grey image

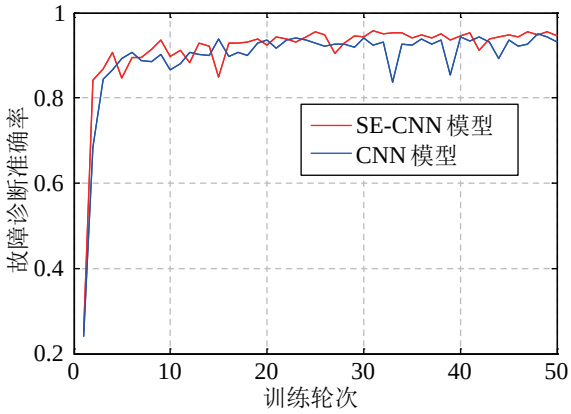

图 10　CNN 与 SE-CNN 故障诊断对比实验

Fig.10　Fault diagnosis comparison between CNN and SE-CNN models

数据，相邻样本间存在大量数据重复，因此不可随机划分测试集与训练集，否则会导致测试集泄露．实验结果如图 10 所示，CNN 模型在测试集上的平均诊断准确率为 93.09%，并且在训练阶段的波动比较大；SE-CNN 模型在训练前期的波动与 CNN 模型相当，而在通道注意力机制的作用下，模型逐渐聚焦了更多鉴别性特征，在训练后期，SE-CNN 模型达到了较高的诊断精度，平均诊断准确率达到 94.41%，并且波动相对较小．

为验证本文所提故障诊断方法在服务机器人故障诊断中的优越性，分别与随机森林（random forest，RF）、XGBoost、长短期记忆（LSTM）网络、CNN 以及文 [26] 方法进行对比，实验结果如图 11 所示．由图可知，RF 和 XGBoost 模型的诊断精度不高，由于只能提取某一时刻的数据特征，表现较为一般．而 LSTM 与 CNN 模型能够提取时间序列数据中的时序特征与关联特征，诊断表现优于传统的故障诊断模型，诊断准确率分别达到 93.24% 与 93.09%；文 [26] 所提出的基于门控循环单元（GRU）与 BP（反向传播）网络的混合故障诊断模型，分别利用 GRU 与 BP 网络提取数据的时序特征以及当前时刻数据的状态特征，取得了优越的故障诊断表现，诊断精度达到了 94.30%；本文的 SE-CNN 故障诊断模型在 CNN 挖掘时间序列数据关联特征的基础上引入了通道注意力机制，使模型聚焦特征图中更有效的特征通道并抑制无效的特征通道，提高了故障诊断精度，达到了 94.41%．

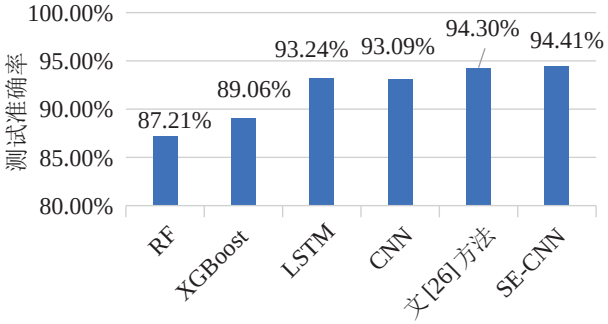

图 11　故障诊断对比实验

Fig.11　Comparative experiments of fault diagnosis

5.3　滑动窗口大小对诊断精度的影响

滑动窗口大小决定了时间序列中所包含的特征信息量，影响故障诊断的精度和实时性．若窗口设定值较小，将导致信息量偏少，无法完整体现关联特征、趋势特征等重要信息，会降低诊断精度；若窗口设定值偏大，将导致模型训练缓慢，降低诊断的实时性．

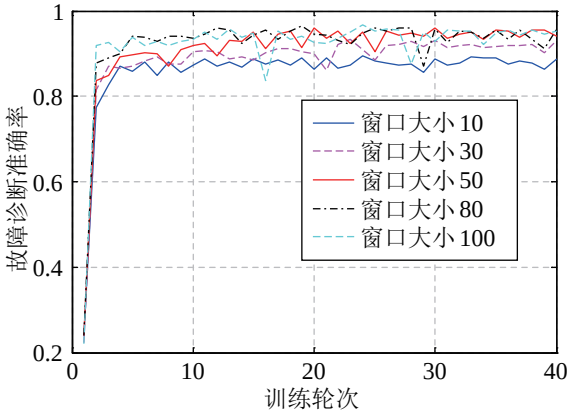

图 12　滑动窗口大小与诊断精度关系曲线

Fig.12　Relation curve between the sliding window size and the diagnosis accuracy

为此，需对滑动窗口大小的设定进行实验研究．调整时间窗大小分别为 10、30、50、80 及 100，实验结果如图 12 所示，当窗口大小设为 10 时，故

障诊断准确率较低，约为 88%；设为 50、80 及 100 时，后 10 轮的平均故障诊断准确率几乎相同，约为 94%．因此，本文设置窗口大小为 50．

5.4 实体服务机器人故障诊断测试

在大量仿真及对比实验的基础上，本文采用运动系统较为复杂的麦克纳姆轮型服务机器人进行了一系列实体测试，如图 13 ～ 16 所示．测试实验中，云端故障诊断模型的推断频率约为 0.8 Hz．

测试 1： 在正常状态下，向机器人下达直行指令．图 13 为服务机器人在室内环境运行过程中的 9 幅截图及云端故障诊断服务给出的实时诊断结果，显示机器人处于“正常”状态．

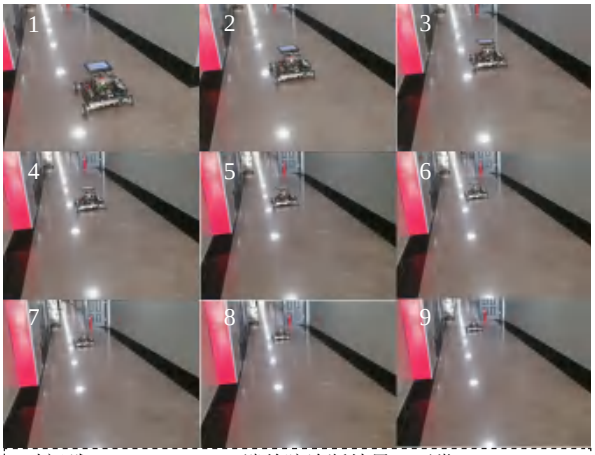

时间戳：1594449830 云端故障诊断结果：正常
时间戳：1594449846 云端故障诊断结果：正常
时间戳：1594449862 云端故障诊断结果：正常
时间戳：1594449877 云端故障诊断结果：正常

图 13 正常运行状态下服务机器人故障诊断实验

Fig.13 Fault diagnosis experiment of a service robot in the normal running state

时间戳：1594451593 云端故障诊断结果：电机轴偏心
时间戳：1594451608 云端故障诊断结果：电机轴偏心
时间戳：1594451624 云端故障诊断结果：电机轴偏心
时间戳：1594451641 云端故障诊断结果：电机轴偏心

图 14 服务机器人电机轴偏心故障诊断实验

Fig.14 Fault diagnosis experiment of a service robot in the fault state of motor axis eccentricity

测试 2： 在服务机器人驱动轮电机轴偏心状态下，向机器人下达直行指令．图 14 为机器人运行时的 9 幅截图及云端实时诊断结果．

由图可见，机器人在直行过程中逐渐偏离规划路线，诊断结果显示“电机轴偏心”，机器人偏离航线一定阈值时，机器人自动停机，避免造成不必要的损失．

测试 3： 在服务机器人左前轮电机无法驱动状态下，向机器人下达直行指令．图 15 为机器人运动时的 9 幅截图，由图可见，机器人无法正常直线行驶，产生原地打转现象，云端故障诊断结果显示机器人“左前轮电机无法驱动”，并自动停机．

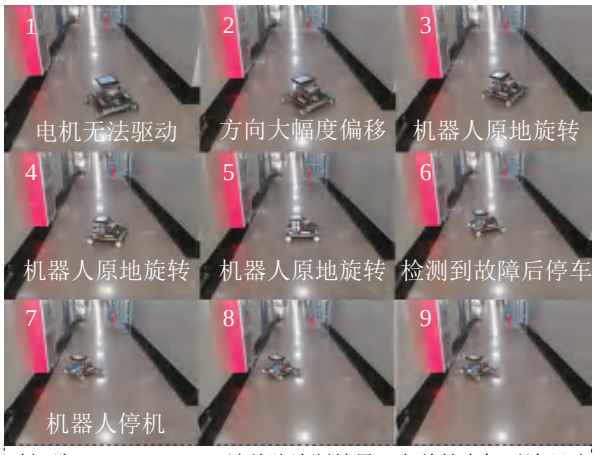

时间戳：1594453266 云端故障诊断结果：左前轮电机无法驱动
时间戳：1594453282 云端故障诊断结果：左前轮电机无法驱动
时间戳：1594453287 云端故障诊断结果：左前轮电机无法驱动
时间戳：1594453303 云端故障诊断结果：左前轮电机无法驱动

图 15 服务机器人电机故障诊断实验

Fig.15 Fault diagnosis experiment of a service robot in the running state of motor fault

时间戳：1594455741 云端故障诊断结果：编码器故障
时间戳：1594455757 云端故障诊断结果：编码器故障
时间戳：1594455772 云端故障诊断结果：编码器故障
时间戳：1594455788 云端故障诊断结果：编码器故障

图 16 服务机器人编码器故障诊断实验

Fig.16 Fault diagnosis experiment of a service robot in the running state of encoder fault

测试 4： 在服务机器人编码器信号线断开状态下，向机器人下达直行指令．图 16 是机器人运行过程中的 9 幅截图及实时显示的故障诊断结果．由图可见，驱动信号加到电机后，机器人未按设计的速度运行，而是突然提速、飞车失控，机器人运动一段距离后自动停机并告警，诊断结果显示“编码器故障”．

实体测试结果表明，无论是较轻微的故障，还是类似失控等严重的故障，本文设计的云端故障诊断系统和提出的诊断方法，均具有较好的实时性和较高的准确性，并在故障情况下自动停车，充分保障了服务机器人运行的安全性．

然而，现有故障诊断方法的时效性易受网络传输效率的约束，在网络情况较好、网络传输效率高的情况下，可以采用云端诊断；在没有网络或网络延时较大时，本文所设计的云诊断架构可以将训练好的故障诊断模型下载至机器人本体，基于本体下载的诊断模型进行故障的实时诊断．随着 5G 通讯网络的商用，该问题有望得到彻底解决．

6　结论（Conclusion）

安全性是服务机器人普及应用的基础和前提，达不到安全性要求的机器人产品不仅会造成财物的损失，甚至可能对用户造成身体或精神上的伤害．基于目前的研究现状和存在的问题，本文创新性地提出了一个基于云服务平台的故障诊断系统框架，巧妙地解决了故障诊断算法所需算力与机器人本体硬件资源之间的矛盾．为了实现服务机器人的精确故障诊断，本文通过 CNN 挖掘时间序列的关联特征，相比传统故障诊断方法提取的某一时刻数据特征，所获取的特征对不同类别数据具有更本质的刻画．其次，本文在 CNN 模型中引入了 SENet，使模型聚焦特征图中更有效的特征通道并抑制无效的特征通道，进一步地提升模型的诊断准确度；最后，通过大量的对比实验与实体测试证明了本文提出的架构及故障诊断方法的优越性和实用性，为服务机器人其他子系统故障诊断研究打下了坚实的基础．

参考文献（References）

[1] 王天然．机器人技术的发展[J]．机器人，2017，39(4)：385-386.
Wang T R. Development of the robotics[J]. Robot, 2017, 39(4): 385-386.

[2] 杨中欣．轮式服务机器人控制系统可靠性设计与安全性研究[D]．济南：山东大学，2018.
Yang Z X. Research on reliability design and security of wheeled service robot control system[D]. Jinan: Shandong University, 2018.

[3] An Z H, Li S M, Wang J R, et al. Generalization of deep neural network for bearing fault diagnosis under different working conditions using multiple kernel method[J]. Neurocomputing, 2019, 352: 42-53.

[4] Zhao Y, Li T T, Zhang X J, et al. Artificial intelligence-based fault detection and diagnosis methods for building energy systems: Advantages, challenges and the future[J]. Renewable and Sustainable Energy Reviews, 2019, 109: 85-101.

[5] Guo L, Lei Y G, Xing S B, et al. Deep convolutional transfer learning network: A new method for intelligent fault diagnosis of machines with unlabeled data[J]. IEEE Transactions on Industrial Electronics, 2019, 66(9): 7316-7325.

[6] Li L L, Ding S X, Yang Y, et al. A fault detection approach for nonlinear systems based on data-driven realizations of fuzzy kernel representations[J]. IEEE Transactions on Fuzzy Systems, 2018, 26(4): 1800-1812.

[7] Yin S, Ding S X, Zhou D H. Diagnosis and prognosis for complicated industrial systems – Part II[J]. IEEE Transactions on Industrial Electronics, 2016, 63(5): 3201-3204.

[8] Wang K, Chen J H, Song Z H. Performance analysis of dynamic PCA for closed-loop process monitoring and its improvement by output oversampling scheme[J]. IEEE Transactions on Control Systems Technology, 2019, 27(1): 378-385.

[9] Xia L L, Zhang S F, Shen R, et al. Data association-based fault diagnosis of IMUs: Optimized DBN design and wheeled robot evaluation[J]. IEEE Access, 2020, 8: 59618-59636.

[10] Zhu Y H, Fu Z Y, Fu Z, et al. Multi-features fusion for fault diagnosis of pedal robot using time-speed signals[J]. Sensors, 2019, 19(1). DOI: 10.3390/s19010163.

[11] Hoang N B, Kang H J. A model-based fault diagnosis scheme for wheeled mobile robots[J]. International Journal of Control, Automation and Systems, 2014, 12(3): 637-651.

[12] 王秀青，侯增广，曾慧，等．基于多传感器信息融合的机器人故障诊断[J]．上海交通大学学报，2015，49(6)：793-798.
Wang X Q, Hou Z G, Zeng H, et al. Fault diagnosis of robots based on multi-sensor information fusion[J]. Journal of Shanghai Jiao Tong University, 2015, 49(6): 793-798.

[13] Khaldi B, Harrou F, Cherif F, et al. Monitoring a robot swarm using a data-driven fault detection approach[J]. Robotics and Autonomous Systems, 2017, 97: 193-203.

[14] Duan Z H, Cai Z X, Min H Q. Robust dead reckoning system for mobile robots based on particle filter and raw range scan[J]. Sensors, 2014, 14(9): 16532-16562.

[15] Yuan X F, Song M M, Zhou F Y, et al. Design of a software simulation platform for fault diagnosis of service robot[C]//IEEE International Conference on Cyber Technology in Automation, Control, and Intelligent Systems. Piscataway, USA: IEEE, 2017: 376-381.

[16] Baghernezhad F, Khorasani K. Computationally intelligent strategies for robust fault detection, isolation, and identification of mobile robots[J]. Neurocomputing, 2016, 171: 335-346.

[17] Khalastchi E, Kalech M. On fault detection and diagnosis in robotic systems[J]. ACM Computing Surveys, 2018, 51(1). DOI: 10.1145/3146389.

[18] Stavrou D, Eliades D G, Panayiotou C G, et al. Fault detection for service mobile robots using model-based method[J]. Autonomous Robots, 2016, 40(2): 383-394.

[19] Zhou B, Qian K, Ma X D, et al. Ellipsoidal bounding set-membership identification approach for robust fault diagnosis with application to mobile robots[J]. Journal of Systems Engineering and Electronics, 2017, 28(5): 986-995.

[20] 刘景泰，张森，孙月．面向智能家居/智慧生活的服务机器人技术与系统[J]．集成技术，2016，5(3)：38-46.
Liu J T, Zhang S, Sun Y. Technology and system of service robots for smart home and intelligent life[J]. Journal of Integration Technology, 2016, 5(3): 38-46.

[21] Kehoe B, Matsukawa A, Candido S, et al. Cloud-based robot grasping with the Google object recognition engine[C]//IEEE International Conference on Robotics and Automation. Piscataway, USA: IEEE, 2013: 4263-4270.

[22] Tenorth M, Perzylo A C, Lafrenz R, et al. Representation and exchange of knowledge about actions, objects, and environments in the RoboEarth framework[J]. IEEE Transactions on Automation Science and Engineering, 2013, 10(3): 643-651.

[23] Kehoe B, Warrier D, Patil S, et al. Cloud-based grasp analysis and planning for toleranced parts using parallelized Monte Carlo sampling[J]. IEEE Transactions on Automation Science and Engineering, 2015, 12(2): 455-470.

[24] Liu J, Zhou F Y, Yin L, et al. A novel cloud platform for service robots[J]. IEEE Access, 2019, 7: 182951-182961.

[25] Yin S, Ding S X, Zhou D H. Diagnosis and prognosis for complicated industrial systems – Part I[J]. IEEE Transactions on Industrial Electronics, 2016, 63(4): 2501-2505.

[26] 郭仁和．基于机器学习的服务机器人云端故障诊断方法研究[D]．济南：山东大学，2019.
Guo R H. Research of service robot cloud fault diagnosis based on machine learning[D]. Jinan: Shandong University, 2019.

作者简介：

缪昭明（1997 –），男，硕士生．研究领域：故障诊断与预测，云服务机器人．

袁宪锋（1989 –），男，博士，讲师．研究领域：服务机器人，故障诊断与预测．